Intro a PLY (Python Lex-Yacc)

Teoría de Lenguajes

Fac. de Ciencias Exactas y Naturales, Universidad de Buenos Aires

1er. cuatrimestre 2016

Introducción

- Sirve para construir analizadores léxicos y sintácticos.
- Implementación de *lex* y *yacc* en python.
- Sitio oficial: `http://www.dabeaz.com/ply/`

Gramática de ejemplo

$$G =< \{E, T, F\}, \{+, *, num, (,)\}, P, E >$$

$$\begin{aligned}
E &\rightarrow E + T \\
E &\rightarrow T \\
T &\rightarrow T * F \\
T &\rightarrow F \\
F &\rightarrow num \\
F &\rightarrow (E)
\end{aligned}$$

Lexer: Introducción

Para generar un lexer, vamos a crear un archivo llamado `lexer_rules.py`, en el cual vamos a definir los tokens y las reglas para detectarlos.

Lexer: Tokens

Tenemos que definir una variable llamada `tokens` que guarde la lista de tipos de tokens que vamos a buscar. Cada tipo se representa con un string:

```
tokens = [
   'NUMBER',
   'PLUS',
   'TIMES',
   'LPAREN',
   'RPAREN'
]
```

Lexer: Reglas

- Cada regla posee una expresión regular para indicar la cadena que se desea capturar.
- Se prueba con todas las reglas, y se utiliza la que más símbolos captura.
- Si dos reglas capturan la misma cantidad de símbolos, se utiliza la que esté definida más arriba en el archivo.
- Una vez seleccionada la regla, se decide el valor del token.
- Comienza de nuevo con el resto de la cadena.
- Termina cuando no queden mas símbolos para leer.

Lexer: Reglas 'simples'

- Solo definen el tipo y la expresión regular.
- El valor queda implícito: es exactamente la cadena que se captura.
- Se definen con variables con el prefijo `t_`.
- El resto del nombre de la variable debe coincidir con el tipo del token.

Lexer: Reglas 'simples' (ejemplo)

```
t_PLUS = r"\+"
t_TIMES = r"\*"
t_LPAREN = r"\("
t_RPAREN = r"\)"
```

- Las cadenas que empiezan con `r` en python se leen en crudo, esto nos permite escribir las \ sin escaparlas.
- Hay que escapar el +, *, (y el) porque son símbolos que forman parte de la sintaxis de expresiones regulares.

Lexer: Reglas 'complejas'

- Se definen con funciones con el prefijo `t_`.
- El resto del nombre de la función debe coincidir con el tipo del token.
- La expresión regular de la regla se define en el *docstring* de la función (ver ejemplo).
- Recibe un token como parámetro, cuyo valor es la cadena capturada.
- El valor se puede modificar.
- Se devuelve el token para generarlo, o no se devuelve nada para descartarlo.

Lexer: Reglas 'complejas' (ejemplo)

```
def t_NUMBER(token):
    r"[1-9][0-9]*"
    token.value = int(token.value)
    return token
```

- El docstring de la función va inmediatamente después de su definición.
- En realidad (como lo dice su nombre) esto se usa en python para documentar la función, pero ply abusa de esta feature.

Lexer: Reglas 'especiales'

- Se pueden crear reglas con el sufijo `t_ignore_` para ignorar tokens capturados por expresiones regulares, ejemplo:

```
t_ignore_WHITESPACES = r"[ \t]+"
```

- Opcionalmente se puede definir la variable `t_ignore`, una cadena (no una expresión regular) que define los caracteres que se ignoran:

```
t_ignore = " \t"
```

Lexer: Manejo de líneas

```
def t_NEWLINE(token):
  r"\n+"
  token.lexer.lineno += len(token.value)
```

- El lexer por defecto no sabe cuándo queremos incrementar el contador de líneas.
- Podemos hacer una regla que maneje los saltos de línea e incremente el contador.
- No devolvemos el token para ignorarlo.

Lexer: Manejo de errores

```
def t_error(token):
    message = "Token desconocido:"
    message = "\ntype:" + token.type
    message += "\nvalue:" + str(token.value)
    message += "\nline:" + str(token.lineno)
    message += "\nposition:" + str(token.lexpos)
    raise Exception(message)
```

- La función `t_error` define qué hacer cuando no se puede *matchear* ninguna regla.
- Ignoramos espacios, tabs y saltos de línea.
- Lanzamos una excepción cuando no se puede *matchear* ninguna regla.

Ejemplo: Ejecutar lexer solo

```
import lexer_rules

from ply.lex import lex

text = "(14 + 6) * 2"
lexer = lex(module=lexer_rules)
lexer.input(text)

token = lexer.token()

while token is not None:
  print token.value
  token = lexer.token()
```

Parser: Introducción

- Para generar un parser, vamos a crear un archivo llamado `parser_rules.py`, en el cual vamos a definir las producciones de la gramática y cómo generar el árbol.
- En este archivo ply nos pide que importemos la lista de tokens que definimos antes:

```
from lexer_rules import tokens
```

- Por otro lado, cada producción debe devolver un nodo del árbol, con lo cual vamos a crear en un archivo llamado `expressions.py` para definir una clase (muy simple) para cada tipo de nodo del árbol, y las incluimos:

```
from expressions import *
```

Parser: Reglas

```
def p_expression_plus(subexpr):
    'expression : expression PLUS term'
    subexpr[0] = Add(subexpr[1], subexpr[3])
```

- Se define una función por cada producción que debe contener el sufijo `p_`, el resto del nombre no importa.
- Esta vez el *docstring* contiene la producción.
- En minúsculas están los no terminales.
- En mayúsculas están los terminales (tokens).
- La función recibe la lista de subexpresiones ya parseadas.
- Los *dos puntos* no forman parte de la lista de subexpresiones.
- El valor de la producción (el nodo parseado) se devuelve modificando el lado izquierdo de la producción.

Parser: Errores

```
def p_error(subexpr):
    raise Exception("Syntax error.")
```

- Pueden definir una función llamada `p_error` para manejar errores.
- Con `subexpr.lineno(i)` pueden obtener el número de línea de la subexpresión `i`.
- Con `subexpr.lexpos(i)` pueden obtener la posición de la subexpresión `i`.
- Por defecto el parser genera un log llamado `parser.out` que pueden mirar.
- Se pueden hacer cosas mas complejas, como intentar corregir los errores o hacer producciones extra que capturen casos de sintaxis errónea conocidos. Hay mas ejemplos en el manual.

Ejemplo: Ejecutar parser

```
import lexer_rules
import parser_rules

from ply.lex import lex
from ply.yacc import yacc

lexer = lex(module=lexer_rules)
parser = yacc(module=parser_rules)

text = "(14 + 6) * 2"
ast = parser.parse(text, lexer)
```

Ejemplo: Abstract Syntax Tree

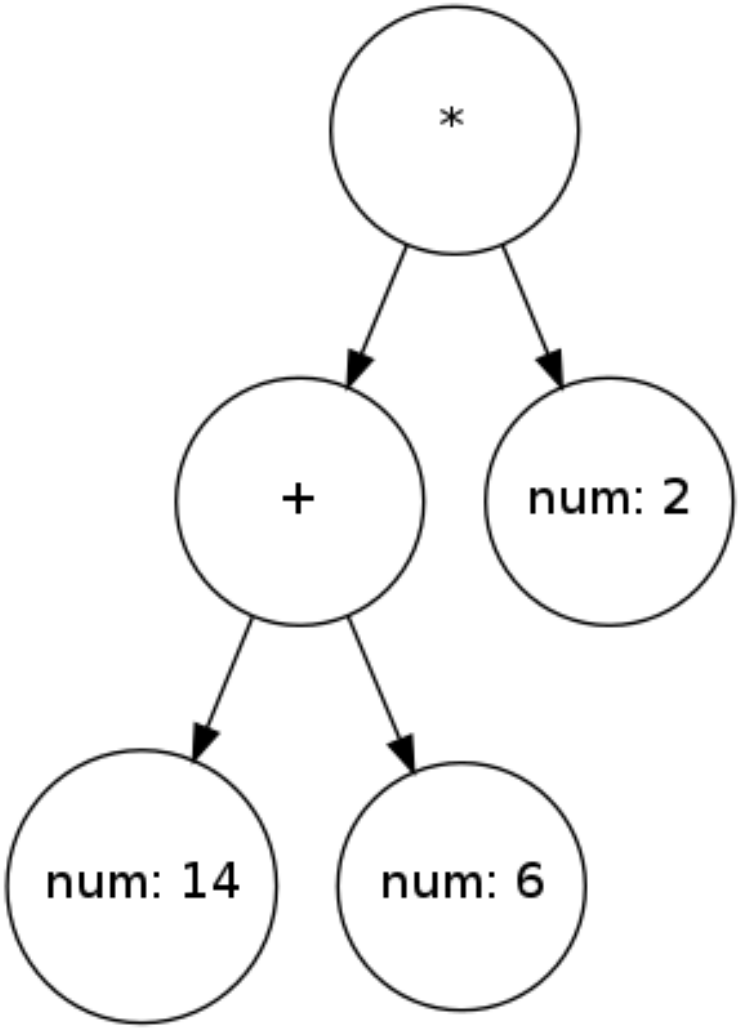

Introducción

- Ya vimos como generar un AST.
- Ahora vamos a ver cómo darle semántica.

Gramática de ejemplo

$$G =< \{E, T, F\}, \{+, *, num, (,)\}, P, E >$$

$$\begin{aligned}
E &\rightarrow E + T \\
E &\rightarrow T \\
T &\rightarrow T * F \\
T &\rightarrow F \\
F &\rightarrow num \\
F &\rightarrow (E)
\end{aligned}$$

Expresiones

- Una vez que tengamos el AST armado, queremos evaluar la expresión aritmética.
- Vamos a pensar cada nodo del AST como una expresión evaluable.

```
class Expression(object):

    def evaluate(self):
        # Aca se implementa cada tipo de expresion.
        raise NotImplementedError
```

Números

- Los nodos más simples son las expresiones numéricas.
- Cuando se evalúan simplemente devuelven el valor del token.

```
class Number(Expression):

    def __init__(self, value):
        self.value = value

    def evaluate(self):
        return self.value
```

Operaciones

- Para este ejemplo la suma y la multiplicación se pueden considerar como operaciones binarias, es decir, que aplican una operación a dos operandos.
- En ambos casos, para evaluar la operación primero necesitamos evaluar cada operando.
- Luego podemos aplicar la operación.

Operaciones binarias

```
class BinaryOperation(Expression):

    def __init__(self, left, right, operator):
        self.left = left
        self.right = right
        self.operator = operator

    def evaluate(self):
        res_l = self.left.evaluate()
        res_r = self.right.evaluate()
        return self.operator(res_l, res_r)
```

Reglas

```
from operator import add, mul
from expressions import BinaryOperation, Number

def p_expression_plus(expr):
    'expression : expression PLUS term'
    expr[0] = BinaryOperation(expr[1], expr[3], add)

def p_term_times(expr):
    'term : term TIMES factor'
    expr[0] = BinaryOperation(expr[1], expr[3], mul)

def p_factor_number(expr):
    'factor : NUMBER'
    expressions[0] = Number(expr[1])
```

Ejecución completa

- Generamos el árbol como antes.
- El nodo raíz representa la expresión completa.
- La evaluamos para saber el resultado total.

```
text = "(14 + 6) * 2"

lexer = lex(module=lexer_rules)
parser = yacc(module=parser_rules)

expression = parser.parse(text, lexer)

result = expression.evaluate()
print result

>> 40
```